ÉCOLE NATIONALE SUPÉRIEURE DES TÉLÉCOMMUNICATIONS ET DES TIC – ORAN
Option : Télécommunications et les Technologies du Numérique

TP N°04 – Machine Learning : Prédiction du Churn Client

Réalisé par : BENKHELIFA Farouk
Module : Apprentissage Automatique
Niveau : IGE 46 – 2025/2026

1 Introduction

Le churn client, ou attrition, désigne le phénomène par lequel un client met fin à sa relation commerciale avec une entreprise. Dans le secteur des télécommunications, ce phénomène revêt une importance stratégique considérable : le coût d'acquisition d'un nouveau client est estimé entre cinq et sept fois supérieur au coût de rétention d'un client existant. La capacité à identifier en amont les clients susceptibles de résilier leur abonnement permet aux opérateurs de déployer des actions de fidélisation ciblées.

Ce travail pratique poursuit plusieurs objectifs :

1. Appliquer les techniques de prétraitement sur un jeu de données réel.
2. Entraîner et comparer deux modèles de classification supervisée.
3. Évaluer les performances selon des métriques adaptées au contexte métier.
4. Interpréter les résultats dans une perspective opérationnelle.

2 Présentation du Dataset

Le jeu de données provient du dataset *IBM Telco Customer Churn* (Kaggle). Il contient **7043 observations** caractérisées par **21 variables**.

La variable cible est **Churn** (Yes/No). Les variables explicatives se répartissent en :

— **Variables numériques (4) :** SeniorCitizen, tenure, MonthlyCharges, TotalCharges.
— **Variables catégorielles (15) :** gender, Partner, Dependents, PhoneService, MultipleLines, InternetService, OnlineSecurity, OnlineBackup, DeviceProtection, TechSupport, StreamingTV, StreamingMovies, Contract, PaperlessBilling, PaymentMethod.

3 Analyse Exploratoire des Données

3.1 Taux global de churn

L'analyse révèle un taux de churn global de **26,5%**, soit 1869 clients sur 7043. Ce déséquilibre de classes (ratio 3 :1) nécessite une attention particulière lors de la modélisation.

3.2 Taux de churn par type de contrat

L'examen du taux de churn selon le contrat met en évidence :

— Contrat mensuel : **42,7%**
— Contrat annuel : **11,3%**
— Contrat bi-annuel : **2,8%**

Les clients sans engagement présentent un risque quinze fois supérieur à celui des clients engagés sur deux ans.

3.3 Visualisation 1 : Taux de churn par contrat

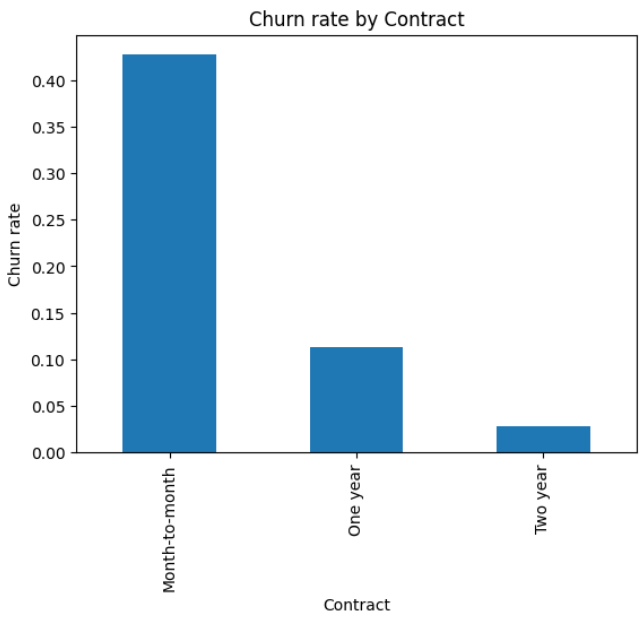

FIGURE 1 – Taux de churn selon le type de contrat. Une forte corrélation est visible.

Le diagramme en barres illustre la relation inverse entre durée d'engagement et risque de churn. Les contrats longue durée créent une barrière à la sortie.

3.4 Visualisation 2 : Frais mensuels par churn

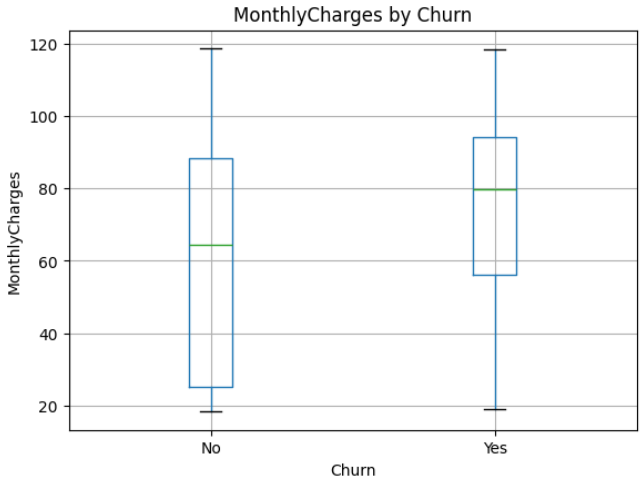

FIGURE 2 – Distribution des frais mensuels selon le churn.

Les clients à risque présentent des montants de facturation médians plus élevés, suggérant une sensibilité au prix.

4 Prétraitement des Données

La stratégie adoptée repose sur un pipeline intégré évitant toute fuite de données lors de la validation croisée.

— **Valeurs manquantes :** Imputation par la médiane (numériques) et le mode (catégorielles).
— **Encodage :** One-hot encoding avec gestion des modalités inconnues.
— **Standardisation :** Centrage-réduction via StandardScaler.

L'ensemble est encapsulé dans un `ColumnTransformer`.

5 Modélisation et Entraînement

5.1 Régression Logistique

La régression logistique modélise la probabilité via une fonction sigmoïde :

$$P(Y = 1|X) = \frac{1}{1 + e^{-(\beta_0 + \beta^T X)}} \tag{1}$$

Une régularisation L1 permet la sélection automatique de variables.

5.2 XGBoost

XGBoost est un algorithme de boosting d'arbres capturant les interactions non linéaires. Le paramètre `scale_pos_weight` compense le déséquilibre.

6 Évaluation des Modèles

Validation croisée stratifiée à 5 folds. Métriques : accuracy et recall (classe Churn).

6.1 Régression Logistique (baseline)

Accuracy : 80,5% — Recall : 55,3% — FN=835, TP=1034

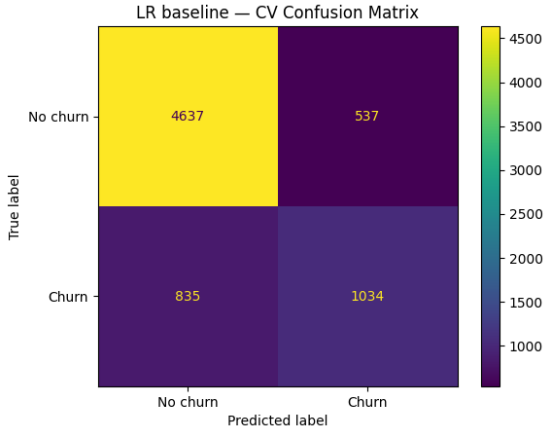

FIGURE 3 – Matrice de confusion – LR baseline

6.2 Régression Logistique (optimisée)

Paramètres : C=0.01, class_weight 1 :4, penalty L1.

Accuracy : 69,2% — Recall : **86,8%** — FN=246, TP=1623

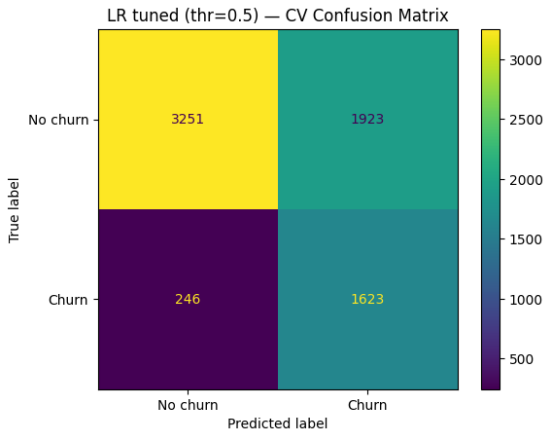

FIGURE 4 – Matrice de confusion – LR optimisée

6.3 LR optimisée + seuil ajusté

Un seuil de décision abaissé augmente le recall au prix de plus de faux positifs.

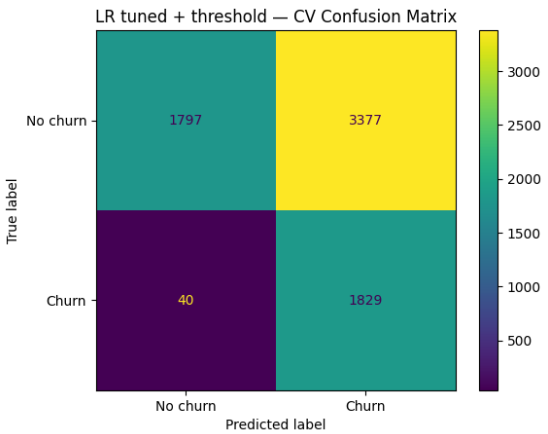

FIGURE 5 – Matrice de confusion – LR optimisée + seuil

6.4 XGBoost (baseline)

Accuracy : 76,0% — Recall : 71,3% — FN=536, TP=1333

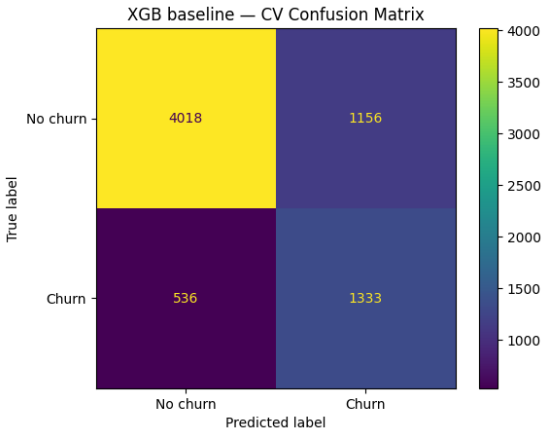

FIGURE 6 – Matrice de confusion – XGBoost baseline

6.5 XGBoost (optimisé)

Paramètres : learning_rate=0.02, max_depth=3, n_estimators=400.

Accuracy : 75,3% — Recall : **80,3%** — FN=368, TP=1501

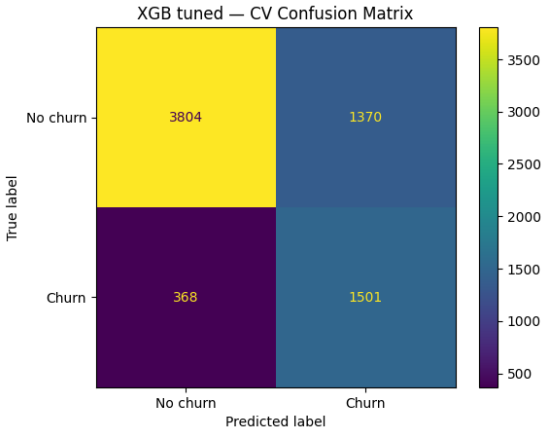

FIGURE 7 – Matrice de confusion – XGBoost optimisé

6.6 Analyse comparative

Modèle	Acc.	Recall	FN
LR baseline	80,5%	55,3%	835
LR optimisée	69,2%	**86,8%**	**246**
XGB baseline	76,0%	71,3%	536
XGB optimisé	75,3%	80,3%	368

TABLE 1 – Comparaison des performances.

La régression logistique optimisée atteint le recall le plus élevé (86,8%). Dans un contexte de détection de churn, la minimisation des faux négatifs prime. Le modèle LR optimisé est retenu.

7 Interprétation Métier

Les clients susceptibles de churn présentent : contrat mensuel, frais mensuels élevés et faible ancienneté. Pour l'opérateur, cela suggère d'inciter la migration vers des contrats annuels, réviser la politique tarifaire et renforcer l'accompagnement des nouveaux abonnés. Le modèle identifie 87% des futurs churners.

8 Conclusion

Ce TP a permis d'appliquer une démarche ML complète sur la prédiction du churn avec un recall de 86,8%.

Limites : Déséquilibre de classes, absence de variables comportementales dynamiques.

Perspectives : Rééchantillonnage (SMOTE), autres algorithmes, ingénierie de features, calibration des probabilités.